



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
UNIVERSITY OF PIRAEUS

Πανεπιστήμιο Πειραιώς

Τμήμα Ψηφιακών Συστημάτων

Π.Μ.Σ «Πληροφοριακά Συστήματα και Υπηρεσίες»

Κατεύθυνση: «Μεγάλα Δεδομένα και Αναλυτική»

Α' εξάμηνο

Μάθημα: Μηχανική Μάθηση

Καθηγητής: Τελέλης Ορέστης

Φοιτητής: Κωστήρης Δημήτριος

ΑΜ: ME25021

ΜΕΤΑΠΤΥΧΙΑΚΗ ΑΠΑΛΛΑΚΤΙΚΗ ΕΡΓΑΣΙΑ ΦΕΒ. 2025-26

Περιγραφή προβλήματος	3
Μέρος Α:	4
Ερώτημα Α:.....	5
Ερώτημα Β:.....	8
Ερώτημα Γ:	11
Μέρος Β:	12
Βιβλιογραφία:.....	14

Περιγραφή προβλήματος

Κατά την εκφώνηση, ορίζονται δύο προβλήματα μηχανικής μάθησης, τόσο πρόβλεψης, όσο και κατηγοριοποίησης. Στο πρώτο σκέλος της εργασίας ζητείται να εργαστούμε πάνω σε ένα σύνολο δεδομένων το οποίο αφορά πωλήσεις στο Ebay, ενώ στο δεύτερο πάνω σε δεδομένα εικόνων. Πιο συγκεκριμένα:

Μέρος 1:

A) Πρόβλεψη τιμής πώλησης.

B) Πρόβλεψη για το αν μια δημοπρασία οδηγήθηκε σε πώληση.

Γ) Αν η τιμή στην οποία έκλεισε η δημοπρασία, εφόσον οδήγησε σε πώληση, είναι μεγαλύτερη/ίση ή μικρότερη από τη μέση τιμή πώλησης του αντικειμένου.

Μέρος 2:

Κατηγοριοποίηση εικόνων, πάνω σε υποσύνολο των κλάσεων, λόγω δυσκολίας του συνόλου δεδομένων.

Σε κάθε υπο-ερώτημα, εφαρμόζονται από δύο διαφορετικές μέθοδοι είτε πρόβλεψης είτε κατηγοριοποίησης, ανάλογα με το ζητούμενο.

Στην παρούσα τεχνική αναφορά γίνεται επεξήγηση των αλγορίθμων που χρησιμοποιήθηκαν, η σύγκριση τους καθώς και των αποτελεσμάτων τους.

Μέρος Α:

Για να είναι πιο ακριβείς οι προβλέψεις, έγινε Scaling στα δεδομένα για να αποφευχθούν αλλοιώσεις στα αποτελέσματα εξαιτίας πολύ μεγάλων ή πολύ μικρών τιμών. Επιπρόσθετα, χρησιμοποιήθηκε η OneHotEncoder τεχνική, έτσι ώστε τυχόν κατηγορικά δεδομένα να μετατραπούν σε δυαδικούς πίνακες, έτσι ώστε το μοντέλο να μπορεί να τα επεξεργαστεί.

Τα μοντέλα εφαρμόστηκαν με τη χρήση Pipeline, σε συνδυασμό με Transformer, για να υπάρξει “καθαρή” και οργανωμένη διαδικασία.

Ερώτημα Α:

Η τιμή - στόχος είναι η Price, ζητείται δηλαδή πρόβλεψη τιμής πώλησης κάθε δημοπρασίας. Εργαζόμαστε στο υποσύνολο δεδομένων των δημοπρασιών οι οποίες οδηγήθηκαν σε πώληση. Οι αλγόριθμοι που χρησιμοποιήθηκαν και θα συγκριθούν είναι:

- 1) Linear Regression
- 2) Gradient Descent


Προεπεξεργασία δεδομένων:

Κατά την προεπεξεργασία, αφαιρούνται οι παρακάτω στήλες από το σύνολο δεδομένων στο οποίο θα εργαστούμε, για να αποφύγουμε διαρροές τιμών και overfitting. Συγκεκριμένα αφαιρούνται οι εξής: Price (target), EbayID, PricePercent, SellerName, PersonID.


Διαγράμματα:

Χρησιμοποιήθηκαν δύο τύποι διαγραμμάτων: Ιστόγραμμα και Box Plot.

Το ιστόγραμμα, φανερώνει την έντονη ασυμμετρία των τιμών. Η πλειοψηφία των τιμών, είναι μικρή, μικρότερη δηλαδή του 50, ενώ υπάρχουν και μερικές ακραίες τιμές (outliers), οι οποίες επηρεάζουν την πρόβλεψη. Συμπερασματικά, επηρεάζονται θετικά οι μικρότερες τιμές και αρνητικά οι μεγαλύτερες.



Το Box Plot, δείχνει πως υπάρχει αρκετά χαμηλό median, ενώ οι ακραίες τιμές δεν αποτελούν θόρυβο.



Linear Regression:

Η γραμμική παλινδρόμηση (Linear Regression) είναι ίσως το πιο κλασικό μοντέλο μηχανικής μάθησης για προβλέψεις. Εφαρμόζει ουσιαστικά τη μέθοδο της αναλυτικής λύση ελαχίστων τετραγώνων.

Αποτελέσματα - Metrics (Linear Regression):

LR RMSE: 1.4906287651213121

LR R2 : 0.9989198308820851

LR MAE : 1.2902980457618003

Παρατηρούμε ότι το μοντέλο απέδωσε σχετικά καλά. Πιο συγκεκριμένα, παρατηρείται απόκλιση τιμής πρόβλεψης από την κανονική ~ 1.4906 , η διακύμανση τιμής εξετάζεται σχεδόν απόλυτα, ~ 0.9989 , ενώ κατά μέσο όρο η απόκλιση πρόβλεψης κυμαίνεται ~ 1.2902 .

Gradient Descent (SGDRegressor):

Η συγκεκριμένη μέθοδος εφαρμόζει την προσπάθεια επαναληπτικής ελαχιστοποίησης του MSE.

Παράμετροι:

- `loss="squared_error"`. Το loss function το οποίο ελαχιστοποιεί το μοντέλο.
- `Learning_rate = "constant"`. Σταθερός ρυθμός μάθησης του μοντέλου.
- `eta0 = 0.00001`. Αποτελεί το μέγεθος βήματος. Χρησιμοποιήθηκε εν τέλει η συγκεκριμένη τιμή καθώς παρουσίασε τα καλύτερα αποτελέσματα. Μεγαλύτερες τιμές έκαναν το μοντέλο να πραγματοποιεί μεγάλα λάθη. Η μικρή τιμή επιλέχθηκε ώστε να διασφαλιστεί ομαλή και σταθερή σύγκλιση του αλγορίθμου, αποφεύγοντας αριθμητική αστάθεια λόγω του υψηλού αριθμού χαρακτηριστικών.

Αποτελέσματα - Metrics (Gradient Descent):

GD RMSE: 1.4951212809488683

GD R2 : 0.9989133101579895

GD MAE : 1.2934004013044138

Το μοντέλο απέδωσε σχεδόν εξίσου καλά, με ελάχιστες αποκλίσεις σε σχέση με την απλή Γραμμική Παλινδρόμηση.

Τελικό Συμπέρασμα -Σύγκριση:

	LR	GD
RMSE	1.490628	1.495121
R2	0.998919	0.998913
MAE	1.290298	1.293400

Συμπερασματικά, παρατηρείται ότι η απλή Γραμμική Παλινδρόμηση, δίνει ελαφρώς καλύτερα αποτελέσματα σε σχέση με την Gradient Descent. Η σχεδόν ταυτόσημη επίδοση δείχνει ότι το Gradient Descent συγκλίνει στη βέλτιστη λύση της γραμμικής παλινδρόμησης, επιβεβαιώνοντας τη σωστή επιλογή learning rate και αριθμού επαναλήψεων. Η Linear Regression βρίσκει την ακριβή βέλτιστη λύση. Άρα οι μικρές διαφορές προκύπτουν από την μαθηματική προσέγγιση από την Gradient Descent.

Ερώτημα Β:

Η τιμή στόχος είναι η QuantitySold. Ζητείται δηλαδή κατηγοριοποίηση 0/1, για το αν η δημοπρασία πουλήθηκε ή όχι. Εργαζόμαστε στο πλήρες σύνολο δεδομένων. Οι αλγόριθμοι κατηγοριοποίησης που χρησιμοποιήθηκαν είναι οι εξής:

- 1) Logistic Regression
- 2) SVM


Προεπεξεργασία Δεδομένων

Κατά την προεπεξεργασία, αφαιρούνται οι παρακάτω στήλες από το σύνολο δεδομένων στο οποίο θα εργαστούμε, για να αποφύγουμε διαρροές τιμών και overfitting. Συγκεκριμένα αφαιρούνται οι εξής: QuantitySold (Target), EbayID, Price (φανερώνει αν πουλήθηκε ή όχι), PricePercent, SellerName, PersonID


Διαγράμματα

Ιστόγραμμα σύγκρισης StartingBid σε Sold vs Unsold

Εμφανίζεται τάση αύξησης πιθανότητας να μην πωληθεί σε περίπτωση αυξημένης αρχικής τιμής. Το feature StartingBid, δείχνει πως είναι αρκετά χρήσιο στην πρόβλεψη του μοντέλου.



Το δεύτερο διάγραμμα δείχνει ότι υπάρχει ανισορροπία στην τιμή στόχο που είναι το QuantitySold. Πιο συγκεκριμένα, σχεδόν το 70% είναι Unsold – 0. Άρα ενδεχομένως το accuracy, να μην μας καλύπτει πλήρως σαν metric.



Logistic Regression:

Παρατηρείται αρκετά καλή και ισορροπημένη απόδοση, χωρίς overfitting, με καλή γενίκευση. Το παραπάνω δηλώνεται μέσω της παρόμοιας απόδοσης του Accuracy, τόσο σε Train όσο και Test επίπεδο.

Train accuracy LR: 0.887865349630609

Test accuracy LR: 0.8882621178854924

Από το classification report παρατηρείται ότι το μοντέλο αναγνωρίζει πολύ αποτελεσματικά την κλάση 0 (unsold), με υψηλό recall (0.9558), ενώ για την κλάση 1 (sold) επιτυγχάνει ικανοποιητική ακρίβεια (precision 0.8771) αλλά χαμηλότερο recall (0.7315), κάτι το οποίο είναι αναμενόμενο δεδομένης της ανισορροπίας των κλάσεων. Επιπλέον παρατηρείται καλύτερο f1 score στην κλάση 0.

	precision	recall	f1-score	support
0	0.8920	0.9558	0.9228	62069
1	0.8771	0.7315	0.7977	26746
accuracy			0.8883	88815
macro avg	0.8845	0.8436	0.8603	88815
weighted avg	0.8875	0.8883	0.8851	88815

Η υψηλή τιμή ROC–AUC δείχνει καλό διαχωρισμό των δύο κλάσεων.

ROC-AUC LR: 0.938328968567541

Συνολικά, η Logistic Regression αποδεικνύεται ένα ισχυρό baseline μοντέλο.

Support Vector Machines (SVM)

Ο δεύτερος αλγόριθμος κατηγοριοποίησης, είναι ο SVM. Ο συγκεκριμένος αλγόριθμος εμφανίζει ελαφρώς χαμηλότερη ακρίβεια σε σχέση με την Logistic Regression. Παρατηρείται ωστόσο καλύτερο Precision στην κλάση 1, δείχνοντας καλύτερες θετικές προβλέψεις. Χρησιμοποιείται η παράμετρος $C = 0.1$, η οποία ορίζει την αυστηρότητα του μοντέλου σε λάθη.

Train accuracy SVM: 0.8851679027954042

Test accuracy SVM: 0.8855598716433035

Classification report SVM				
	precision	recall	f1-score	support
0	0.8852	0.9608	0.9215	62069
1	0.8866	0.7109	0.7891	26746
accuracy			0.8856	88815
macro avg	0.8859	0.8359	0.8553	88815
weighted avg	0.8856	0.8856	0.8816	88815

Τελικό Συμπέρασμα -Σύγκριση:

Συνοψίζοντας και τα δύο μοντέλα έχουν καλή απόδοση, με την Logistic Regression να υπερέχει οριακά σε ακρίβεια σε σχέση με το SVM. Η Logistic Regression κρίνεται καταλληλότερη καθώς επιτυγχάνεται καλύτερη ισορροπία μεταξύ Precision και Recall.

Ερώτημα Γ:

Στο τρίτο ερώτημα, ζητείται κατηγοριοποίηση για το αν η τιμή στην οποία έκλεισε η δημοπρασία (Price), εφόσον οδήγησε σε πώληση, είναι μεγαλύτερη/ίση ή μικρότερη από τη μέση τιμή πώλησης του αντικειμένου. Θα χρησιμοποιηθεί το σύνολο δεδομένων των δημοπρασιών που οδηγήθηκαν σε πώληση. Οι αλγόριθμοι κατηγοριοποίησης που χρησιμοποιήθηκαν είναι οι εξής:

- 3) Logistic Regression
- 4) SVM

Προεπεξεργασία Δεδομένων

Κατά την προεπεξεργασία, αφαιρούνται οι παρακάτω στήλες από το σύνολο δεδομένων στο οποίο θα εργαστούμε, για να αποφύγουμε διαρροές τιμών και overfitting. Συγκεκριμένα αφαιρούνται οι εξής: Price, AvgPrice, EbayID, PersonID, SellerName, PricePercent

Logistic Regression:

Ο συγκεκριμένος κατηγοριοποιητής, έχει καλό Accuracy ~0.885 και Precision, ενώ παρατηρείται ικανοποιητικό Recall στην κλάση ενδιαφέροντος ~0.758. Υπάρχει καλή γενίκευση του μοντέλου.

Train accuracy LR: 0.8829865674991184

Test accuracy LR: 0.8851821377814346

Classification Report (LR)				
	precision	recall	f1-score	support
0	0.8984	0.9410	0.9192	18552
1	0.8501	0.7587	0.8018	8186
accuracy			0.8852	26738
macro avg	0.8742	0.8499	0.8605	26738
weighted avg	0.8836	0.8852	0.8833	26738

Confusion Matrix:

17457	1095
1975	6211

Support Vector Machines (SVM):

Ο συγκεκριμένος κατηγοριοποιητής παρουσιάζει παρόμοια απόδοση, με ελαφρώς χαμηλότερο Accuracy, το F1-score για την κλάση $\text{Price} \geq \text{AvgPrice}$ είναι ελαφρώς χαμηλότερο (≈ 0.80), με μικρότερη τιμή recall, γεγονός που δείχνει ότι το SVM είναι πιο συντηρητικό στην πρόβλεψη της θετικής κλάσης. Παρόλα αυτά, το μοντέλο εμφανίζει καλή γενίκευση, χωρίς ενδείξεις υπερπροσαρμογής.

Train accuracy SVM: 0.8818164331741096

Test accuracy SVM: 0.8843593387687935

Classification Report (SVM)					
	precision	recall	f1-score	support	
0	0.8952	0.9438	0.9189	18552	
1	0.8548	0.7496	0.7988	8186	
accuracy			0.8844	26738	
macro avg	0.8750	0.8467	0.8588	26738	
weighted avg	0.8828	0.8844	0.8821	26738	

Confusion Matrix:

17510	1042
2050	6136

Τελικό Συμπέρασμα - Σύγκριση

Κάνοντας την τελική σύγκριση των κατηγοριοποιητών, παρατηρούμε παρόμοια και ικανοποιητική απόδοση, ωστόσο οριακά υπερέχει ο αλγόριθμος Logistic Regression.

Μέρος Β:

Στο δεύτερο μέρος της εργασίας ζητείται εφαρμογή 2 κατηγοριοποιητών πάνω στο σύνολο δεδομένων CIFAR-10, κάνοντας Classification εικόνων.

Οι αλγόριθμοι που χρησιμοποιήθηκαν είναι οι εξής:

- Logistic Regression
- K-NN

Προεπεξεργασία Δεδομένων

Αρχικά, πραγματοποιείται φόρτωση των δεδομένων, με βάση το επίσημο documentation. Στη συνέχεια ορίζεται X και y , τα οποία χωρίζονται σε Train και Test data.

Στη συνέχεια, εξαιτίας της δυσκολίας του προβλήματος, ορίζονται οι υποκλάσεις bird, cat, dog. Η κατηγοριοποίηση θα πραγματοποιηθεί μόνο για αυτές.

Στη συνέχεια εφαρμόζεται τόσο Scaling όσο και PCA, για μείωση των διαστάσεων σε 150. Ο αριθμός αυτός, απέδωσε τα καλύτερα αποτελέσματα σε σχέση με άλλες δοκιμές που έγιναν.

Logistic Regression

Τα αποτελέσματα δείχνουν ακρίβεια περίπου ~ 0.54 , με σχετικά ισορροπημένες τιμές precision, recall και f1-score μεταξύ των επιλεγμένων κλάσεων. Η κλάση bird εμφανίζει την καλύτερη επίδοση ($f1 \sim 0.61$), γεγονός που υποδηλώνει ότι τα οπτικά χαρακτηριστικά της διαχωρίζονται ευκολότερα. Αντίθετα, οι κλάσεις cat και dog παρουσιάζουν μεγαλύτερη απόκλιση, κάτι που επιβεβαιώνεται από το Confusion Matrix, όπου παρατηρούνται λάθη μεταξύ αυτών των δύο κατηγοριών. Συνολικά, η Logistic Regression λειτουργεί ως ένα ικανοποιητικό baseline, εμφανίζοντας τιμές λογικές για ένα τέτοιο πρόβλημα.

Classification Report LR:				
	precision	recall	f1-score	support
2	0.5811	0.6380	0.6082	1000
3	0.5137	0.5060	0.5098	1000
5	0.5245	0.4810	0.5018	1000
accuracy			0.5417	3000
macro avg	0.5398	0.5417	0.5399	3000
weighted avg	0.5398	0.5417	0.5399	3000

Confusion Matrix Logistic Regression

638	203	159
217	506	277
243	276	481

K- Nearesr Neighbors (KNN)

Ο συγκεκριμένος ταξινομητής αποδίδει χαμηλότερη ακρίβεια ~0.51, σε παράμετρο k γειτόνων 10, η οποία απέδωσε και τα καλύτερα αποτελέσματα από όσες δοκιμάστηκαν. Επιπλέον παρατηρούνται ανισορροπίες σε Precision και Recall ανά κλάση. Υπάρχει έντονη σύγχυση μεταξύ των κλάσεων, κάτι το οποίο παρατηρείται και στο Confusion Matrix.

Train accuracy KNN: 0.5754666666666667

Test accuracy KNN: 0.5116666666666667

Classification Report KNN:					
	precision	recall	f1-score	support	
2	0.4666	0.8720	0.6079	1000	
3	0.5507	0.3370	0.4181	1000	
5	0.6281	0.3260	0.4292	1000	
accuracy			0.5117	3000	
macro avg	0.5484	0.5117	0.4851	3000	
weighted avg	0.5484	0.5117	0.4851	3000	

Confusion Matrix KNN

872	75	53
523	337	140
474	200	326

Τελικό Συμπέρασμα - Σύγκριση

Συμπεραίνουμε ότι η Logistic Regression αποδίδει καλύτερα αποτελέσματα και είναι καταλληλότερη μέθοδος, καθώς ο ταξινομητής KNN δεν μπορεί να ανταπεξέλθει στην πολυπλοκότητα του συγκεκριμένου προβλήματος.

Βιβλιογραφία:

- 1) <https://www.geeksforgeeks.org/machine-learning/precision-and-recall-in-machine-learning/>

- 2) <https://scikit-learn.org/stable/>
- 3) <https://www.cs.toronto.edu/~kriz/cifar.html>
- 4) <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>